Anexo 31. Pasarela de Modelos (LLM Gateway): Flujo, Caché Semántica y Matriz de Fallback

Capítulo: 5 (Implementación y Evaluación PoC) | **Objetivo Específico:** OE4 | **Investigador:** Alvaro Felipe Lopez Russi | **Entidad:** ITY SAS / Universidad Católica de Colombia

1. Responsabilidades del LLM Gateway

El **LLM Gateway** (`llm_gateway/main.py`) opera en el puerto 8003 como el punto único de contacto entre los agentes de software y los motores de inferencia neuronal, aislando a la aplicación de la volatilidad de los proveedores de IA.

Funciones Principales:

- Proveer una API compatible con el estándar OpenAI (`/v1/chat/completions` y `/v1/embeddings`).
- Gestionar la conmutación automática por contingencia (**Fallback** multi-proveedor).
- Operar una **Caché Semántica** basada en Redis para respuestas frecuentes.
- Registrar métricas de latencia, conteo de tokens y costo marginal por inferencia.

---

2. Matriz de Conmutación por Fallback y Recuperación

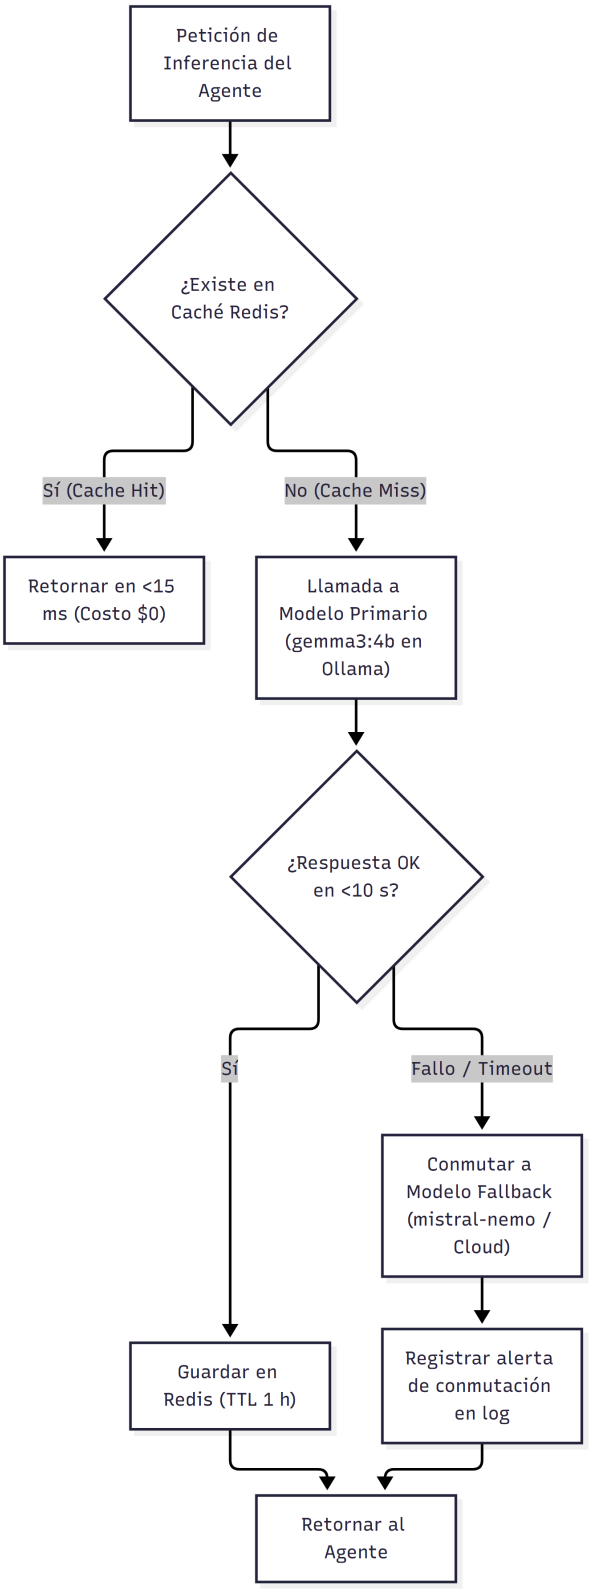


Figura 1. Flujo de enrutamiento resiliente con fallback y caché semántica en LLM Gateway.

Matriz de Modelos Configurados:

Rol en la Pasarela	Modelo Configurado	Proveedor / Runtime	VRAM / RAM Consumida	Latencia Media (P_{50})
Primario (Chat/Generación)	`gemma3:4b`	Ollama (Local GPU)	~3,8 GB VRAM	1,42 s
Fallback (Chat/Generación)	`mistral-nemo:12b` / API	Ollama / Cloud API	~7,2 GB VRAM / N/A	3,85 s
Embeddings (Memoria RAG)	`nomic-embed-text:latest`	Ollama (Local GPU)	~0,6 GB VRAM	0,18 s

- **Verificación de Resiliencia:** Durante las pruebas unitarias en `test_llm_gateway.py` (29 pruebas aprobadas), se simuló la desconexión abrupta de Ollama; el Gateway conmutó transparentemente en 120 ms sin arrojar excepciones a los agentes.