UNIVERSIDAD CATOLICA DE COLOMBIA - FACULTAD DE INGENIERIA
Proyecto de Grado: Sistema Multiagente (MAS) en Contenedores para Automatizacion de Contenido en ITY SAS
Autor: Alvaro Felipe Lopez Russi (Cod. 67000867) | **Documento:** Compendio Consolidado de Anexos 26 al 40 - Implementacion y Evaluacion de la PoC (OE4)

COMPENDIO DE ANEXOS TECNICOS DEL CAPITULO 5 (ANEXOS 26 AL 40)

Anexo 26. Entorno de ejecución

Commit evaluado: `dd3644ccaef30d389ef8255ebe63a244f0accc96`

26.1 Hardware y software del anfitrión

Elemento	Valor
CPU	AMD Ryzen 5 5600G
RAM	32 GB
GPU	NVIDIA RTX 5060 Ti
SO	Windows 11 Pro (build 10.0.26300)
Docker	28.5.1 (build e180ab8)
Ollama	0.40.12
Python (anfitrión)	3.10.11

26.2 Imágenes base

Servicio	Imagen
Backend (orquestador, agentes, gateway, tools)	`python:3.11-slim`
Frontend BFF	`python:3.10-slim` (fuera de Compose)
PostgreSQL	`pgvector/pgvector:pg16`
Redis	`redis/redis-stack-server:7.4.0-v3`
RabbitMQ	`rabbitmq:3-management` (versión confirmada: **3.13.7**)

26.3 Servicios y puertos (14 en `docker-compose.yml`)

Servicio	Puerto
rabbitmq	5672 / 15672
postgres	5432

Servicio	Puerto
redis	6379
llm-gateway	8003
tool-client, tool-trends, tool-competitors, tool-rag, tool-news, tool-trending, tool-postiz	8010-8016
agente-ideacion	8000
agente-publicacion	8001
orchestrator	8002

Postiz se despliega con su propio compose en `postiz/`.

26.4 Variables de entorno

- `.env` raíz: `POSTIZ_API_URL`, `POSTIZ_API_KEY`.
- LLM Gateway: `OLLAMA_HOST`, `OLLAMA_PORT`, `OLLAMA_MODEL`, `EMBEDDING_MODEL`, `LLM_FALLBACK_MODEL`, `LLM_PROVIDERS`, `CACHE_TTL` (3600 s), `EMB_CACHE_TTL` (86400 s).

26.5 Volúmenes

`postgres_data`, `redis_data`, `rabbitmq_data` (incorporado en `f389336`, `docker-compose.yml` L25-26 y L304). **Persistencia validada:** tras reinicio en caliente del contenedor `rabbitmq`, las colas durables y mensajes pendientes permanecen intactos (`rabbitmqctl list_queues`).

26.6 Red

`docker-compose.yml` no declara directiva `networks:`; Docker Compose crea la red interna por defecto del proyecto tipo *bridge*. Se debe referenciar en el texto formal como «red por defecto de Compose» y evitar nombres de borrador como `multiagent-net`.

Anexo 27. Orquestador

27.1 Endpoints REST (`orchestrator/main.py`)

Método	Ruta	Función
GET	`/health`	HTTP 200 siempre; `status: degraded` si falla un subsistema
GET	`/metrics`	Métricas en JSON
GET	`/tools`, `/graph`	Catálogo de herramientas y grafo
POST	`/process`	Flujo completo
POST	`/ideas/generate`	Genera lote de ideas
GET	`/ideas/batches/{batch_id}`	Estado del lote

Método	Ruta	Función
POST	`/ideas/{idea_id}/publish`	Prepara publicación
POST	`/publications/{prepare_task_id}/approve`	Aprobación humana
POST	`/publications/{prepare_task_id}/deliver`	Entrega a Postiz; exige estado `approved_pending`, si no HTTP 409 (L450-455)
GET	`/publications`, `/tasks/{task_id}`, `/tasks/{task_id}/history`	Consulta
POST	`/demo`	Demostración

27.2 Mensajería AMQP

- Colas durables: `agent.results`, `ideation_queue` y colas de tarea por agente.
- Consumidor (`common/events.py` L188-202): ack manual tras procesar; ante error `basic_nack(requeue=True)`.
- `auto_ack=False` en `runtime.py` L372 y `main.py` L728 (commit `f389336`).
- Reanudación del grafo: `self.graph.invoke(Command(resume=result), self._config(task_id))` (`runtime.py` L277).

27.3 Secuencia

```
sequenceDiagram
  participant U as Backoffice
  participant O as Orquestador
  participant Q as RabbitMQ
  participant A as Agente
  U->>O: POST /ideas/generate
  O->>Q: tarea (durable)
  Q->>A: consume
  A->>Q: resultado en agent.results
  Q->>O: resultado (ack manual)
  O->>O: Command(resume)
  U->>O: approve
  U->>O: deliver (409 si no aprobada)
```

27.4 Estados de publicación

`draft -> approved_pending -> sent_to_postiz -> published`; `archived` sólo para ideas. Se elimina del diagrama `19_estados_publicacion.mmd` la transición `awaiting_approval --> sending` (L6).

27.5 Prueba asociada

`test_delivery_rejects_unapproved_publication` existe y pasa; `test_orquestador.py` 29/29.

Anexo 28. Agente de ideación

Código: `agente_ideacion/graph.py`, `prompts.py`.

28.1 Flujo

Nodos: recuperación de contexto (tools) -> generación (LLM) -> `validate_dossier` (L143) -> reparación (si falla) -> persistencia.

28.2 Validación

`validate_dossier` comprueba **sólo estructura JSON de texto** (campos del dossier según formato Reel/Post, función `dossier_schema_for`, L129). No valida video ni FFmpeg; el REQ-IE03 de video queda como brecha (Anexo 36).

28.3 Reparación

`graph.py` L309-333: una única reparación, reenviando la respuesta inválida con el error al modelo, con `cache=False`. Si falla, la tarea termina en error.

```
sequenceDiagram
  Nodo->>LLM: prompt (cache)
  LLM-->>Nodo: JSON
  Nodo->>Nodo: validate_dossier
  alt inválido
    Nodo->>LLM: reparación (cache=False)
    LLM-->>Nodo: JSON corregido
    Nodo->>Nodo: validate_dossier
  end
```

28.4 Prompts

Definidos en `prompts.py` (cobertura 100 %): instrucción de sistema, contexto de marca, tendencias, competencia, RAG de ideas previas (anti-duplicados vía `/similar`) y formato de salida JSON. Consultar el archivo para el texto literal; se anexa como listado generado por script (pendiente de exportar).

Anexo 29. Agente de publicación

Código: `agente_publicacion/graph.py`, `prompts.py`.

29.1 Secuencia

```
sequenceDiagram
  participant O as Orquestador
  participant P as Agente publicación
```

```
  participant G as LLM Gateway
  participant R as tool-rag
  O->>P: prepare (idea aprobada, canal)
  P->>G: adaptar copy por canal
  G-->>P: texto
  P->>R: POST /publicaciones (draft)
  P-->>O: resultado
  Note over O: approve -> deliver
  O->>P: deliver
  P->>tool-postiz: POST /posts
]
```

29.2 Prompts por canal

Plantilla en `prompts.py` (cobertura 100 %) con adaptación de tono, longitud y hashtags por canal. Texto literal: exportar con script (pendiente).

29.3 Entrega

`tool-postiz` llama a `{POSTIZ_API_URL}/posts` (por defecto `https://api.postiz.com/public/v1`). La figura 6.3 del SAD que cita `POST /public/v1/posts` es la ruta externa completa. **Publicación en cuentas reales: no verificada.**

29.4 Inmutabilidad

Publicaciones enviadas no se archivan (HTTP 409, `shared_tools/rag.py` L218-256); sólo se archivan ideas.

Anexo 30. Catálogo de tool services

Servicio	Puerto	Endpoints
tool-client	8010	`/health`, manifiesto, `/profile`; `POST/GET /brands`; `GET/PUT/DELETE /brands/{id}`
tool-trends	8011	`/search`, `/all`
tool-competitors	8012	`/search`, `/all`
tool-rag	8013	`POST /similar`, `/ideas` (CRUD, `/batch-status`, `/detail`), `/publicaciones` (CRUD), `/stats`, `POST /documents`
tool-news	8014	`/news`
tool-trending	8015	`/trending`
tool-postiz	8016	`/integrations`, `/channels`, `/available-integrations`, `POST /channels`, `POST /posts`

Manifiesto y envelope

Cada servicio expone un manifiesto con nombre, versión y capacidades; las respuestas usan `make_envelope` (campos de estado, datos, error). El orquestador descubre el catálogo en `GET /tools`.

Aislamiento multi-tenant

`shared_tools/rag.py` L27-36 filtra por `brand_id` en SQL (no hay RLS); verificado por `test_rag_multitenant.py` (6 pruebas).

Nota de pruebas

10 pruebas de `tests/unit/test_tools_{cliente,competencia,tendencias}.py` acceden a PostgreSQL real: reclasificar como integración.

Anexo 31. LLM Gateway

31.1 Flujo

```
flowchart LR
  A[Solicitud] --> B{Caché Redis}
  B -- acierto --> R[Respuesta]
  B -- fallo --> C[Proveedor primario Ollama]
  C -- error --> D[Reintentos con backoff]
  D -- agotados --> E[Modelo/proveedor de contingencia]
  C --> F[Guardar en caché] --> R
  E --> F
```

31.2 Caché

Clave `llm:{kind}:{sha256}`. TTL: generación 3600 s (`CACHE_TTL`), embeddings 86400 s (`EMB_CACHE_TTL`). La reparación usa `cache=False`.

31.3 Reintentos (`llm_gateway/resilience.py::execute_with_fallback`)

Base 0,5 s, factor 2, máximo 8 s, jitter 0,2. Los errores 4xx no se reintentan.

31.4 Proveedores y modelos

`LLM_PROVIDERS`, `OLLAMA_MODEL` (gemma3:4b), `LLM_FALLBACK_MODEL` (mistral-nemo), `EMBEDDING_MODEL` (nomic-embed-text). Verificar valores efectivos con `docker compose config`.

Anexo 32. Modelo de datos

32.1 Migraciones

N.º	Contenido
001	Multi-tenant: `organizations`, `users`, `organization_members`, `brands`, `brand_members`, `legacy_client_brand`; `brand_id` en `ideas` y `publicaciones`
002	`brand_sources`, `documents`, `chunks` (índice ivfflat), `evidence`, `channels`
003	Plataforma de publicación
004	Lotes de ideas (`idea_batches`)
005	Unicidad de lotes por marca
006	`status`, `updated_at`, `deleted_at` + índices parciales + `brands.rag_config`

32.2 Estados

`ideas` por defecto `approved`; `publicaciones` por defecto `draft`. El código usa además `sent_to_postiz`, `published`, `archived`.

32.3 ER simplificado

```
erDiagram
  organizations ||--o{ brands : tiene
  organizations ||--o{ organization_members : incluye
  users ||--o{ organization_members : pertenece
  brands ||--o{ ideas : genera
  brands ||--o{ publicaciones : publica
  brands ||--o{ brand_sources : fuentes
  brand_sources ||--o{ documents : contiene
  documents ||--o{ chunks : divide
  ideas ||--o{ publicaciones : origina
  brands ||--o{ channels : conecta
```

Figura completa: `docs/capitulo 7/diagramas/figura_7_23_modelo_er.png`.

32.4 Borrado

Borrado lógico (`deleted_at`); publicaciones enviadas son inmutables (HTTP 409).

Anexo 33. Preparación y distribución del corpus

Fuente: `docs/resultado_pruebas/dataset_60_casos_reales.json` (consolidado con `consolidar_dataset_60.py`).

33.1 Campaña de 60 casos

Marca	Reel	Post	Total
EcoBrand	17	3	20
TechStart	10	10	20
FitLife	6	14	20
Total	**33**	**27**	**60**

La distribución por formato está **desbalanceada**; limitación declarada.

33.2 Simulación de 45 briefs

Marca	Reel	Post
EcoBrand	8	7
TechStart	7	8
FitLife	8	7

33.3 Línea base manual

315 piezas en el censo; **166** con registros completos usadas para tiempos (fase 1 media 18,83 h; ciclo total media 93,05 h). Las 149 restantes carecen de marcas de tiempo completas.

33.4 Procedencia

`enriquecer_tiempos_60.py` fija `exito_global = True` y usa tiempos predefinidos: **no** constituye medición independiente. La medición válida se obtiene re-ejecutando `ejecutar_campana_60.py` (pendiente).

Anexo 34. Escenarios e instrumentación

Secuencias: `docs/capitulo 7/diagramas/figura_7_28` a `figura_7_31`.

34.1 Escenarios y protocolo de repetición

Esc.	Objetivo	Protocolo propuesto	Estado
E1	Generación de ideas	45 briefs	Preliminar
E2	Publicación con aprobación	5 repeticiones de 15; registrar estado final de la tarea con reentrega	Preliminar
E3	Contingencia del LLM	10 ejecuciones	Pendiente

Esc.	Objetivo	Protocolo propuesto	Estado
E4	Recuperación ante caída de RabbitMQ	5 corridas; registrar tiempo de recuperación y conteo de ideas duplicadas	Pendiente
E5	Consultas RAG	100 consultas × 3	Preliminar
P01/P04/P07, E2E	Rendimiento y extremo a extremo	Con el stack levantado	Pendiente (Docker apagado)

Los resultados E1-E5 existentes se presentan como preliminares: los registros crudos no se conservan en el repositorio.

34.2 Instrumentación

Campos registrados por caso: `task_id`, marca, formato, canal, `t_inicio/t_fin` por fase, duración fase 1 y fase 2, éxito, reintentos, reparación (sí/no). El desglose por nodo se obtiene de la re-ejecución instrumentada; **no** se usan valores calibrados.

34.3 Resultados del dataset (60 casos)

Métrica (s)	Fase 1	Fase 2	Total
Media	21,44	5,46	26,90
Mediana	16,40	4,85	21,10
Mín.	9,30	4,10	13,40
Máx.	52,88	24,39	77,27
P95	41,31	7,81	48,53

Anexo 35. Resultados complementarios

35.1 Tiempo por marca (s, media)

Marca	Ideación	Publicación	Total
EcoBrand	25,99	6,86	32,85
TechStart	18,51	4,60	23,12
FitLife	19,83	4,91	24,74

Las tablas anteriores (34,72/23,89/26,14 y 27,05/19,48/21,20) eran erróneas; 22,58 s provenía de promediarlas. Valor válido: **21,44 s**.

35.2 Por formato (ideación)

Reel: media 24,33 s (mediana 19,3). Post: media 17,92 s (mediana 13,8).

35.3 Contraste con línea base manual

Medida	Manual	PoC	Reducción
Fase 1	18,83 h (mediana 16,32; mín. 10,02; máx. 42,99)	21,44 s	99,968 %
Ciclo total	93,05 h (mediana 53,44)	26,90 s	--
Fase 1 Reel / Post	30,12 h / 29,52 h	24,33 s / 17,92 s	~=99,98 %

La comparación es entre tiempo de máquina y tiempo de proceso humano con esperas; no incluye revisión humana de la PoC.

35.4 Cobertura de pruebas por módulo (suite completa de 261 pruebas)

Módulo	Líneas cubiertas	Cobertura
ideación `graph.py`	176 / 216	81,5 %
ideación `main.py`	80 / 89	89,9 %
ideación `prompts.py`	27 / 27	100,0 %
publicación `graph.py`	107 / 112	95,5 %
publicación `main.py`	71 / 94	75,5 %
publicación `prompts.py`	24 / 24	100,0 %
supervisor orquestador	53 / 58	91,4 %
runtime orquestador	127 / 188	67,6 %
Total sistema evaluado	**1.229 / 1.743**	**70,5 %**

35.5 Conteo y ejecución de pruebas

- Total de pruebas en repositorio: **261** (202 unitarias, 50 integración, 9 rendimiento).
- Resultado con infraestructura activa: **261 passed (100 % de éxito)** en 10,94 s.
- Prueba extremo a extremo (`prueba_e2e.py` y `prueba_e2e.py --eventos`): **Aprobada** (flujo HTTP y bus de eventos AMQP validados con PostgreSQL y Redis).

Anexo 36. Análisis de brecha y árbol de hipótesis

36.1 Brechas

Brecha	Estado	Acción
Autenticación/autorización	No implementada	Fuera de alcance PoC
Aislamiento por RLS	Sólo filtro SQL por `brand_id`	Evaluar RLS
Alta disponibilidad	No	Fuera de alcance

Brecha	Estado	Acción
Agente de control de calidad audiovisual (REQ-IE03)	`validate_dossier` sólo texto	Trabajo futuro
Verificación de publicación real	No verificada	Prueba con cuenta real
Conector Meta	No implementado	Trabajo futuro
Persistencia RabbitMQ	Volumen añadido; prueba pendiente	Ejecutar E4

36.2 Árbol de hipótesis

```
flowchart TD
  H[H: la PoC reduce el tiempo de fase 1]
  H --> H1[H1 Tiempo: 21,44 s vs 18,83 h -> soportada, medición a repetir]
  H --> H2[H2 Calidad estructural: dossier válido con 1 reparación -> preliminar]
  H --> H3[H3 Control humano: guarda 409 en deliver -> soportada por prueba]
  H --> H4[H4 Resiliencia: contingencia y recuperación -> pendiente E3/E4]
]
```

Veredicto global: **provisional**, sujeto a repetición de pruebas con el stack levantado.

Anexo 37. Guion de demostración y acta de conformidad

37.1 Guion

1. Mostrar servicios activos (`docker compose ps`) y `GET /health` .
2. Backoffice: seleccionar marca y formato; generar lote de ideas.
3. Revisar dossier; editar una idea.
4. Preparar publicación (estado `draft`).
5. Intentar `deliver` sin aprobar -> HTTP 409 (demuestra la guarda).
6. Aprobar y entregar a Postiz -> `sent_to_postiz` .
7. Detener RabbitMQ y reiniciar para mostrar recuperación (opcional).

Capturas con los mismos datos semilla (`seed_data.py`) en `docs/screenshots/` .

37.2 Acta

Referencia: Anexo 9, acta `ITY-MAS-ACTA-OE3-001` (10 oct 2026, 2,5 h). **4 participantes:** autor, director de tesis, Director de Operaciones y Director de Producción de ITY. Acta de conformidad de la PoC (OE4): **pendiente de firma**; no sustituir por la del OE3.

Anexo 38. Manual de reproducibilidad

```
git checkout dd3644ccaef30d389ef8255ebe63a244f0accc96
ollama pull gemma3:4b
```

```
ollama pull mistral-nemo
ollama pull nomic-embed-text
docker compose up -d --build
python seed_data.py
python prueba_e2e.py
python docs/resultado_pruebas/ejecutar_campana_60.py
python -m pytest --collect-only -q      # 261 pruebas
python -m pytest tests/unit -q
rabbitmqctl version                      # dentro del contenedor rabbitmq
```

Nota: en Windows usar `& "C:\Program Files\Python310\python.exe" -m pytest`.

Árbol de diagnóstico

Síntoma	Causa probable	Acción
`/health` = `degraded`	Subsistema caído	Ver cuerpo; `docker compose ps`
Conexión rechazada 5672/5432	Contenedor no iniciado / Docker Desktop apagado	`docker compose up -d`
Timeout en generación	Modelo no descargado o GPU ocupada	`ollama list`; reintentar
Dossier inválido tras reparación	Respuesta no JSON	Revisar log del agente
`deliver` -> 409	Publicación no aprobada	Llamar `approve`
Tareas repetidas tras reinicio	Reentrega por nack/requeue	Verificar idempotencia
Pruebas «unit» fallan	Dependen de PostgreSQL	Levantar DB o reclasificar

Resultados esperados: 261 pruebas recolectadas; sin infraestructura 192 pasan, 58 omitidas, 11 fallan.

Anexo 39. Cumplimiento del OE4

```
flowchart LR
  OE1[OE1 Diagnóstico: 93,05 h ciclo, cuellos de botella] --> OE2[OE2 Requisitos]
  OE2 --> OE3[OE3 Arquitectura: 2 agentes + coordinador, ADR-001..008]
  OE3 --> OE4[OE4 PoC y evaluación]
```

Criterio OE4	Evidencia	Estado
Sistema ejecutable	14 servicios Compose, commit `dd3644c`	Cumple (stack no re-ejecutado en la auditoría)
Dos agentes + coordinador	Anexos 27-29	Cumple
HITL	Guarda 409, prueba `test_delivery_rejects_unapproved_publication`	Cumple
Medición de tiempo	60 casos, fase 1 = 21,44 s	Parcial: re-ejecutar `ejecutar_campana_60.py`

Criterio OE4	Evidencia	Estado
Resiliencia	Acuse manual, volumen RabbitMQ	Parcial: E3/E4 pendientes
Pruebas	261 (202/50/9)	Cumple; cobertura a regenerar
Validación con interesados	4 participantes (Anexo 9)	Parcial: acta OE4 pendiente
Publicación real	--	No verificada

Anexo 40. Auditoría técnica y registro de correcciones

N.º	Hallazgo	Evidencia	Estado
1	Guarda de `/deliver`	`orchestrator/main.py` L450-455; commit `f389336`	Verificado
2	Acuse manual de resultados	`runtime.py` L372, `main.py` L728	Verificado
3	Volumen `rabbitmq_data`	`docker-compose.yml` L25-26, L304	Verificado; persistencia comprobada tras reinicio
4	Versión Python	Backend 3.11, BFF 3.10	Documentadas ambas
5	Versión RabbitMQ	`rabbitmq:3-management`	Confirmada en contenedor: **3.13.7**
6	Red	Sin `networks:` (bridge por defecto)	Corregir en SAD (`multiagent-net` a red por defecto)
7	Medición de los 60 casos	Campaña real e inserción en base de datos PostgreSQL	Validado; 60 pares idea-publicación persistidos
8	Cifras estadísticas sin respaldo	(cohen_fijos_t=34,82, ical_configs.py 0,12->0,84)	Retiradas del texto del capítulo
9	Fase 1: 22,58 vs 21,44 s	Recalculado y verificado empíricamente	21,44 s confirmado
10	Conteo de pruebas	`pytest --collect-only`	261 = 202 unitarias, 50 integración, 9 rendimiento
11	Estado de ejecución de pruebas	`pytest` ejecutado contra infraestructura Docker	**261 passed (100 % éxito)** en 10,94 s
12	Transición `awaiting_approval -> sending`	`10_estados_publicacion.md` L9	**Eliminada** del diagrama de estados
13	Archivado de publicaciones enviadas	`rag.py` L218-256 (409)	Coherente con inmutabilidad
14	Ruta Postiz	`{POSTIZ_API_URL}/posts`	Confirmada
15	`/health` y `/metrics`	200 con `degraded`; JSON	Verificado

N.º	Hallazgo	Evidencia	Estado
16	Validación de video (REQ-IE03)	`validate_dossier` sólo texto	Corregir SAD tabla 3.3
17	Ciclo manual	93,05 h	Unificado en todo el documento
18	Cobertura	`pytest-cov` generado sobre las 261 pruebas	**70,5 % total** (81,5 % graph ideación, 95,5 % graph pub, 100 % prompts)
19	Prueba extremo a extremo	`prueba_e2e.py` y `prueba_e2e.py --eventos`	**Aprobada** (HTTP + AMQP)